

```
PS C:\Users\李庚容> wsl -d Ubuntu-22.04
root@LAPTOP-2PVGABC5:/mnt/c/Users/李庚容# curl http://127.0.0.1:30000/v1/models
{"object": "list", "data": [{"id": "/mnt/e/WSL/models/Qwen3-0.6B", "object": "model", "created": 1790505870, "owned_by": "sglang", "root": "/mnt/e/WSL/models/Qwen3-0.6B", "parent": null, "max_model_len": 40960}]}
root@LAPTOP-2PVGABC5:/mnt/c/Users/李庚容# curl http://127.0.0.1:30000/v1/chat/completions \
-H "Content-Type: application/json" \
-d '{
  "model": "Qwen/Qwen3-0.6B",
  "messages": [{"role": "user", "content": "简单解释KV Cache是什么"}],
  "temperature": 0.7
}'

{"id": "8d7833ded2ad454e86312388cf25eb3b", "object": "chat.completion", "created": 1790505906, "model": "Qwen/Qwen3-0.6B", "choices": [{"index": 0, "message": {"role": "assistant", "content": "<think>\n嗯，用户问的是“简单解释KV Cache是什么”，首先我需要确定他们对计算机网络和缓存技术的基本理解程度。可能他们刚接触这些概念，或者需要一个更简单的解释来理解技术细节。</think>\n首先，KV Cache通常指的是键值缓存（Key-Value Cache），也就是内存中的键值对缓存。这类缓存用于临时存储数据，以便后续访问时快速检索。但用户可能不太清楚它的具体作用和实现方式，所以需要从基础开始解释。</think>\n接下来，我应该考虑用户可能的深层需求。他们可能想知道如何使用KV Cache，或者为什么需要它，或者它和传统缓存的区别。需要确保解释清晰，避免术语堆砌，同时保持易懂。</think>\n还要注意用户可能对技术细节不太熟悉，比如内存中的数据结构，或者缓存如何工作。可能需要用简单比喻，比如把键值对看作订单信息，缓存保存这些信息，避免多次请求同一订单。</think>\n另外，可能需要提到KV Cache的作用，比如提高访问速度，减少延迟，或者存储大量数据。同时，解释它的优势和应用场景，帮助用户理解为什么它重要。</think>\n最后，检查是否有遗漏的信息，确保回答全面且易于理解，避免专业术语过多，保持口语化，让用户能够轻松掌握概念。</think>\n\n**KV Cache (Key-Value Cache) ** 是一种内存中的缓存结构，用于临时存储数据，以提高访问速度。它的核心作用是：</think>\n1. **存储数据**：将需要频繁访问的键值对数据（如订单信息、用户信息等）存入内存中。</think>\n2. **快速检索**：当数据再次被访问时，直接从缓存中读取，减少延迟。</think>\n3. **优化性能**：减少数据库或服务器的请求次数，提升整体响应速度。</think>\n\n**简单来说**：就像你有一张“临时账本”：每次你需要数据时，先去“账本”里找，这样就不会每次都从数据库“跑腿”了。</think>\n\n", "reasoning_content": null, "tool_calls": null, "logprobs": null, "finish_reason": "stop", "matched_stop": "151645"}], "usage": {"prompt_tokens": 13, "total_tokens": 433, "completion_tokens": 420, "prompt_tokens_details": null, "reasoning_tokens": 0}, "metadata": {"weight_version": "default"}}}
root@LAPTOP-2PVGABC5:/mnt/c/Users/李庚容#
```

WARNING: Running pip as the 'root' user can result in broken permissions and conflicting usage of pip. It is recommended to use pipx instead: <https://pip.pypa.io/warnings/venv>

root@LAPTOP-2PVGABC5:/mnt/e/WSL# python3 /mnt/e/WSL/workload_sender.py
开始执行workload，总请求数：20

请求 1		trace输入token: 512		trace输出token: 128
请求 2		trace输入token: 768		trace输出token: 192
请求 3		trace输入token: 64		trace输出token: 16
请求 4		trace输入token: 128		trace输出token: 48
请求 5		trace输入token: 512		trace输出token: 128
请求 6		trace输入token: 64		trace输出token: 16
请求 7		trace输入token: 64		trace输出token: 16
请求 8		trace输入token: 256		trace输出token: 64
请求 9		trace输入token: 320		trace输出token: 80
请求 10		trace输入token: 512		trace输出token: 128
请求 11		trace输入token: 1024		trace输出token: 256
请求 12		trace输入token: 384		trace输出token: 96
请求 13		trace输入token: 128		trace输出token: 32
请求 14		trace输入token: 128		trace输出token: 32
请求 15		trace输入token: 96		trace输出token: 24
请求 16		trace输入token: 96		trace输出token: 24
请求 17		trace输入token: 512		trace输出token: 128
请求 18		trace输入token: 192		trace输出token: 48
请求 19		trace输入token: 128		trace输出token: 32
请求 20		trace输入token: 192		trace输出token: 64

ID	InTok	OutTok	Status	TTFT(s)	Latency(s)
1	512	128	200	0.1709	0.171
2	768	192	200	0.0187	0.0188
3	64	16	200	0.0151	0.0152
4	128	48	200	0.0176	0.0177
5	512	128	200	0.0173	0.0174
6	64	16	200	0.0121	0.0122
7	64	16	200	0.0127	0.0128
8	256	64	200	0.0144	0.0145
9	320	80	200	0.0153	0.0154
10	512	128	200	0.0162	0.0163
11	1024	256	200	0.0185	0.0185
12	384	96	200	0.0122	0.0122
13	128	32	200	0.0117	0.0117
14	128	32	200	0.0126	0.0127
15	96	24	200	0.0133	0.0133
16	96	24	200	0.0109	0.011
17	512	128	200	0.0134	0.0135
18	192	48	200	0.0123	0.0124
19	128	32	200	0.0122	0.0123
20	192	64	200	0.012	0.012

完整指标已保存到 /mnt/e/WSL/workload_result.csv
root@LAPTOP-2PVGABC5:/mnt/e/WSL#